

KDD Cup 2012 Track 1 解题报告

张作柏

17300240035

2019 年 6 月 13 日

目录

1	任务简介	1
1.1	任务描述	1
1.2	数据信息	1
1.2.1	名词定义	1
1.2.2	数据文件	1
1.2.3	注意事项	2
1.3	提交格式	3
1.4	评价方式	3
1.5	为什么使用 Julia?	3
2	数据预处理	4
2.1	会话分析	4
2.2	成对训练	5
3	用户兴趣模型	6
3.1	基本模型	6
3.2	成对训练	6
3.3	年龄、性别因素	6
3.4	间接反馈信息	6
3.5	关键词、标签信息	6
3.6	用户、物品信息	6

4	用户行为模型	7
4.1	时间度量	7
4.2	概率预测	7
5	集成学习 Adaboost	8
5.1	模型原理	8
5.2	训练方法	8
6	结果评估	9
6.1	测试模块	9
6.2	测试结果	9
7	代码说明	9
	参考文献	10

1 任务简介

本次 PJ 我选择了 KDD Cup 2012 Track 1 题目¹，其中模型主要参考了 [1] 一文。

1.1 任务描述

近年来，随着像 Facebook、Twitter、腾讯微博等社交平台的发展，在线社交网络引起了广泛的关注。全中国最大的微博系统之一，腾讯微博，已经成为网络社交的重要平台。目前，腾讯微博拥有超过 2 亿的注册用户，每天产生四千万条信息。海量的数据引起了数据挖掘爱好者的注意，如何利用数据信息改善用户的使用体验，成为了一个十分有趣并值得研究的问题。

本任务中，我们需要根据用户的兴趣，预测他是否会关注某个对象 (item)。对象可以是某个组织、个人、群体等等。最终我们要在所有备选推荐中，选择至多三个对象推荐给用户。

1.2 数据信息

1.2.1 名词定义

对象 (item): 对象是腾讯微博中的一个用户，他可以代表组织、个人或群体。数据集中大约有六千个不同的对象。

发微博 (tweet): 发微博是指用户可以在微博系统中发表一条信息，他的关注者会看到这条信息的提醒。

转发 (retweet): 用户可以转发其他用户发表的信息，并在其下添加评论。

评论 (comment): 用户可以在别人的微博下发表评论。

关注者 (follower): 用户可以关注其他用户，若用户 A 关注了 B，则称 A 是 B 的关注者。

1.2.2 数据文件

1. **训练数据集 rec_log_train.txt:** 记录了用户与对象之间的历史推荐结果。

文件格式: (UserId) (ItemId) (Result) (Unix-timestamp)

在 Unix-timestamp 的时间，系统向用户 UserId 推荐了物品 ItemId，得到的结果为 Result。Result 为 1，表示接受；Result 为 -1，表示拒绝。

2. **测试数据集 rec_log_test.txt:** 记录了测试集中用户与对象之间的可能推荐。

文件格式同训练数据集 rec_log_train.txt

区别在于其中 Result 域为 0，需要我们来预测。

¹<https://www.kaggle.com/c/kddcup2012-track1>

3. **用户信息 user_profile.txt**: 记录了用户的详细个人资料。

文件格式: (UserId) (Year-of-birth) (Gender) (Number-of-tweet) (Tag-Ids)

依次表示用户的 Id, 出生日期, 性别, 发表的微博数量和标签。其中, 出生日期将以年份的形式给出; 性别为 0、1、2, 分别代表未知、男性、女性; 标签是由用户选择的代表个人兴趣的关键词, 有的用户没有选择标签, 标签的格式为: tag-id1;tag-id2;...;tag-idN, 其中每个标签用正整数来表示, 如果一个用户没有任何标签的话, 那么他的 tag-id 为 0。

4. **对象数据 item.txt**: 记录对象的属性, 包含它所属的类别与关键词。

文件格式: (ItemId) (Item-Category) (Item-Keyword)

依次表示对象的 Id, 对象所属的类别 (以 “a.b.c.d” 的格式给出, 表示所属的子类别), Item-Keyword 是从对象的个人资料中提取的关键词, 以 “id1;id2;...;idN” 的形式给出。

5. **用户行为 user_action.txt**: 记录了用户在微博上的行为, 包括艾特、转发和评论。

文件格式: (UserId) (Action-Destination-UserId) (Number-of-at-action) (Number-of-retweet) (Number-of-comment)

假如用户 A 转发了 B 的微博 5 次, '@'B 共 3 次, 评论 6 次, 则相应的数据为 “A B 3 5 6”。

6. **用户关注行为 user_sns.txt**: 描述用户的关注信息。

文件格式: (Follower-userid) (Followee-userid)

表示前者关注了后者。

7. **用户关键词描述 user_key_word.txt**: 记录了从用户的微博信息中提取的关键词。

文件格式: (UserId) (Keywords)

其中关键词的格式为 “kw1:weight1;kw2:weight2;...kwN:weightN”。关键词是从用户的微博中提取的, 可以用来预测用户的兴趣, 权值表示用户对某个关键词的感兴趣程度, 权值越大, 越感兴趣。每个关键词都用唯一的整数表示, 并与 item 的关键词共用一个字典。

1.2.3 注意事项

以下是一些没有在题目中给出, 但是我在数据处理的过程中发现的问题:

- 对象 item 的 ID 与用户 user 的 ID 是共用一个词典的, 即每个 ItemId 也对应一个 UserId。
- 用户的性别并非只有 0、1、2 三种, 还有性别为 3 的用户。
- 用户填写的出生年中存在非法数据, 格式不正确, 不是年份的形式。

1.3 提交格式

原提交网站上的提交格式说明消失了，我是从别人的博客上看到的，并结合讨论区的评论和自己的一些理解，总结出的以下格式。

测试集 `rec_log_test.txt` 中包含了不重复的 34,910,937 对用户与对象，以及相应的推荐时间，但未给出推荐的结果。文件是按照时间顺序排序的，时间 $< 1,321,891,200$ 的记录将被用于 `public leaderboard`，而时间 $\geq 1,321,891,200$ 的记录将被用于 `private leaderboard` 的最终评测。我们的目标是预测每个集合中推荐给用户的 `item`。

因为腾讯的默认设置是最多推荐三个 `item` 给用户，所以在每个测试集上，我们需要为每个用户推荐至多三个 `item`，且按照顺序排序，这将在评价指标的度量中起到作用。

最终提交时，上传一个 `.csv` 文件，文件总共两列，包括 `UserId` 与 `ItemIds`，分别表示用户的 `Id` 和推荐给他的对象 `Id`。`public leaderboard` 数据在前，`private` 数据在后，分别按照用户 `Id` 升序排列，推荐的对象按照推荐顺序排序。最终提交的文件中必须恰好包含 1,340,127 行。

1.4 评价方式

本次比赛使用的是 MAP(Mean Average Precision) 作为评价指标，计算方式如下：

$$ap@n = \sum_k P(k) / (\text{用户接受总数}), \quad (1)$$

其中 $P(k)$ 表示前 k 个物品中用户接受的个数，若物品 k 未被接受，则规定 $P(k) = 0$ 。

在该任务中，我们至多推荐三个 `item` 给用户，故 $n = 3$ ，`item` 按顺序记为 #1,#2,#3。

假如用户总共接受了 3 个物品，分别是 #1,#3,#4，那么 $ap@3 = (\frac{1}{1} + \frac{2}{3})/3 \approx 0.56$ 。

假如用户总共接受了 4 个物品，分别是 #1,#2,#4，那么 $ap@3 = (\frac{1}{1} + \frac{2}{2})/3 \approx 0.67$ 。

假如用户总共接受了 2 个物品，分别是 #1,#3，那么 $ap@3 = (\frac{1}{1} + \frac{2}{3})/2 \approx 0.83$ 。

1.5 为什么使用 Julia ?

Julia 是一种用于科学计算的新兴语言，其最大的特点是速度快，号称兼具 Python 的便捷性与 C 的速度。在本次项目中，我使用了 Julia 语言，一是因为想要熟悉一下这门新的语言，并在后续的研究中使用，二是因为 Python 的效率太低，且对于本任务并无太大用处，所以不妨使用新的 Julia 语言。

因为在这次的 PJ 中，我的训练过程是手写的，未使用自动求导的模块，所以其中涉及到大量的矩阵、向量运算。而 Julia 对于这些线性代数操作，支持许多快速的算法，具有与 MATLAB 比肩的数值分析运算能力。这也是我使用 Julia 的主要原因之一。

2 数据预处理

本节主要介绍在数据预处理过程中使用的方法，主要方法与 [1] 一文相同，有一些小细节进行了改动。

2.1 会话分析

训练集中共有 73,209,277 个训练数据，其中涉及 1,392,873 个用户和 4,710 个对象。其中，包含 5,253,828 个正例和 67,955,449 个负例。可以看到，负例的个数远超过正例的个数，那实际上所有的负例都是有效的吗？其实不然。这些记录是从现实生活中的用户浏览记录中提取的，而实际中我们自己在浏览微博时，更多是关注于微博的内容，而不是微博的推荐内容。所以用户没有接受一个推荐，并不一定说明用户真的对这个对象不感兴趣，而有可能是因为用户并没有意识到这个推荐。因此，为了便于我们对用户的兴趣建模，我们需要先剔除一部分的噪声数据。

这里，我认为论文中的方法不是很正确，且实现后发现得到的数据与论文中给出的并不一致，所以我没有完全照搬论文中的方法。

因为每个用户的浏览习惯是不同的，这一点主要体现在浏览时长上。对于每个用户，我们对将所有对他的推荐，按时间顺序排序，然后计算相邻两个推荐时刻之间的间隔，即

$$\Delta t_s = t_{s+1} - t_s, \quad (2)$$

其中， t_s 和 t_{s+1} 分别对应第 s 个推荐时刻和第 $s+1$ 个推荐时刻。这里需要注意，因为会有对象在同一时刻被推荐，所以这里要计算相邻两个时刻，而非相邻两个对象的时间间隔。

我们需要将用户的推荐记录划分为若干个时间段，时间段之间是互相独立的，因此需要先计算一个阈值 τ ，当相邻时间间隔大于等于 τ 时，则说明可以将两边划分为两个互不影响的时间段。那么，为了避免过大的时间间隔的影响，我们在确定阈值时，只考虑相邻间隔不超过一个小时的数值，即如果 $\Delta t_s < 3600$ 的话，我们将其记为 $\ddot{\Delta t}_s$ ，只考虑这一部分时间间隔。对所有的时间间隔取平均，得到阈值

$$\tau = \frac{1}{2} \times (\tau_0 + \frac{\sum_s \ddot{\Delta t}_s}{|\ddot{\Delta t}|}). \quad (3)$$

其中， $|\ddot{\Delta t}|$ 表示不超过一小时的时间间隔个数。取 $\tau_0 = 90$ ，计算得到阈值 τ ，对于大于 τ 的时间间隔，我们把它分为两个时间段。

现在，我们将第 k 个时间段中的样本集合记为 Φ_k ，其中的正样本记为 Φ_k^+ 。记出现最早的正样本的下标记为 σ_- ，最晚出现的记为 σ_+ ，那么对于下标为 σ_s 的样本，我们进行如下过滤：

1. 若该时间段出现的正样本过多，则说明可能这是噪声数据，将这个时间段中的数据全部剔除，即只选择 $0 < \frac{|\Phi_k^+|}{|\Phi_k|} \leq \epsilon$ 的时间段，其中取 $\epsilon = 0.86$ 。

2. 我们在下标区间 $\sigma_- - \pi_-$ 到 $\sigma_+ + \pi_+$ 中选取样本, 即样本 σ_s 需要满足 $\sigma_- - \pi_- \leq \sigma_s \leq \sigma_+ + \pi_+$ 。这一限制是基于假设: 用户可能在意识到第一个正样本之前, 一直没有关注到推荐, 可能在接受最后一个正样本之后, 就没有再留意推荐信息。这里, 为了减少样本数量, 提高训练效率, 我们取 $\pi_+ = \pi_- = 1$ 。

最后, 经过数据清洗, 我们得到 3,794,928 个正例和 11,193,905 个负例, 总共约一千五百万的训练数据, 数据量缩减五倍, 这大大提升了训练的效率。

2.2 成对训练

不同于寻常的二分类问题, 在这一问题中, 我们需要对所有的推荐物品进行排序, 这更像是一个学习排名的问题 [2]。实践证明 [3] [4] [5], 以分类问题中常使用的 MSE (Mean Square Error) 作为目标函数进行训练的效果不是很好。在这一问题中, 我们使用更加适合排名问题的成对训练方法。这一方法在推荐系统中的应用比较广泛, 且非常适合排名问题。

成对训练的基本思路是, 将一个正例与一个负例组合, 通过训练使得正例的概率尽可能的高于负例的概率。如何构造成对的组合呢? 对于每个用户, 因为负例的数量较多, 所以我们对于它的每一个负例, 随机挑选一个正例与它匹配, 最终, 我们将得到 11,193,905 个训练样本。

3 用户兴趣模型

3.1 基本模型

3.2 成对训练

3.3 年龄、性别因素

3.4 间接反馈信息

3.5 关键词、标签信息

3.6 用户、物品信息

4 用户行为模型

4.1 时间度量

4.2 概率预测

5 集成学习 Adaboost

5.1 模型原理

5.2 训练方法

6 结果评估

6.1 测试模块

6.2 测试结果

7 代码说明

参考文献

- [1] Yunwen Chen, Zuotao Liu, Daqi Ji, Yingwei Xin, Wenguang Wang, Lu Yao, and Yi Zou. Context-aware ensemble of multifaceted factorization models for recommendation prediction in social networks. In *KDD-Cup Workshop*, 2012.
- [2] Tie-Yan Liu et al. Learning to rank for information retrieval. *Foundations and Trends® in Information Retrieval*, 3(3):225–331, 2009.
- [3] Johannes Fürnkranz and Eyke Hüllermeier. Pairwise preference learning and ranking. In *European conference on machine learning*, pages 145–156. Springer, 2003.
- [4] Steffen Rendle and Christoph Freudenthaler. Improving pairwise learning for item recommendation from implicit feedback. In *Proceedings of the 7th ACM international conference on Web search and data mining*, pages 273–282. ACM, 2014.
- [5] Amit Sharma and Baoshi Yan. Pairwise learning in recommendation: experiments with community recommendation on linkedin. In *Proceedings of the 7th ACM Conference on Recommender Systems*, pages 193–200. ACM, 2013.